Laporan Aplikasi MewScrapper

Kelas: A1-D4 / Kelompok: A1

Anggota Kelompok:

Anindya Jauzaa Rusyana	251525001
Bima Anugrah Prasetyo	251524004
Irfan Ramadhan	251524014
Muhammad Faqih Shiam	251524023
Muhammad Fatih Izzul Haq	251524024

Deskripsi Singkat Aplikasi

Aplikasi ini merupakan sebuah sistem web scraping berita yang dirancang untuk mengumpulkan data artikel secara otomatis dari sebuah website portal berita. Pengguna hanya perlu memasukkan URL halaman berita, kemudian sistem akan menelusuri halaman tersebut untuk mengumpulkan link artikel yang tersedia. Selanjutnya, aplikasi akan mengunjungi setiap artikel untuk mengekstrak informasi penting seperti judul berita, tanggal publikasi, isi artikel, dan URL.

Data yang berhasil diperoleh ditampilkan secara langsung pada antarmuka aplikasi dan dapat disaring berdasarkan rentang tanggal tertentu sesuai kebutuhan pengguna. Hasil scraping kemudian dapat disimpan dalam format CSV atau Microsoft Excel sehingga mudah digunakan untuk analisis data, dokumentasi, maupun penelitian. Dengan proses ini, aplikasi membantu mempercepat dan mengotomatisasi pengumpulan data berita dari internet.

Library yang Digunakan

No.	Library	Fungsi
1	selenium	Otomatisasi browser Chrome untuk scraping
2	webdriver-manager	Auto-download ChromeDriver sesuai versi Chrome
3	PyQt5	Framework pembuatan GUI desktop
4	openpyxl	Export data ke format Excel (.xlsx)
5	dateparser	Parse format tanggal bahasa Indonesia dan Inggris
6	beautifulsoup4	Parsing HTML sebagai helper ekstraksi
7	newspaper3k	Ekstraksi artikel dan metadata dari website berita

Diagram Arsitektur Sistem

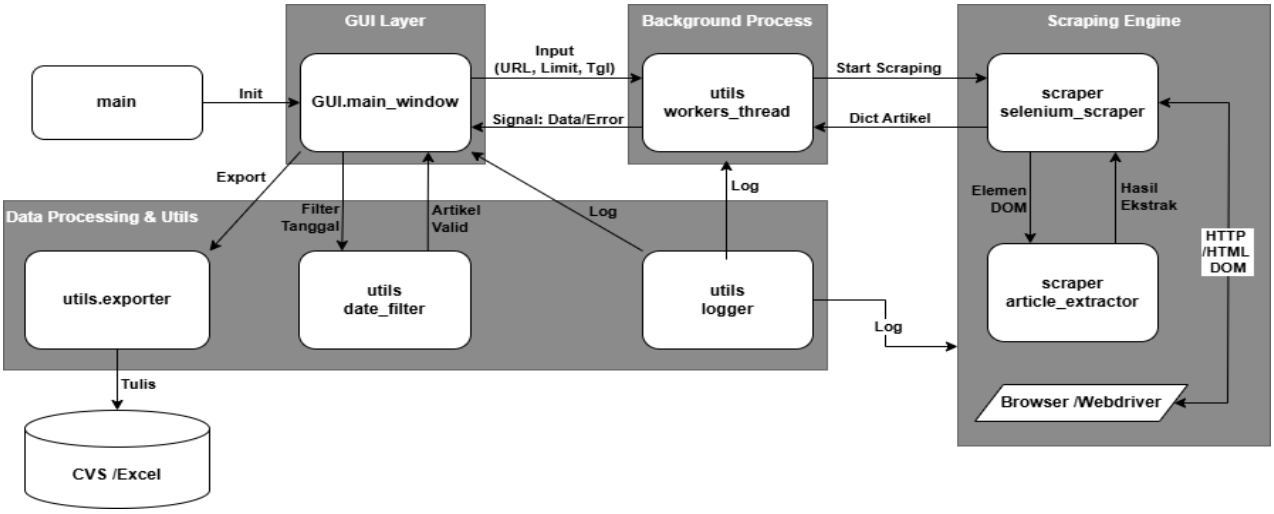

Penjelasan Aliran Data & Interaksi Modul

1. **main.py (Entry Point):**
   - Titik awal aplikasi yang menjalankan PyQt5 dan menginisialisasi main_window.

2. **GUI Layer (gui.main_window):**
   - interaksi pengguna (input URL, filter tanggal, limit jumlah artikel, tombol Start/Stop).
   - Menerima input pengguna dan mengirimnya sebagai argumen untuk memulai utils.worker_thread.
   - Menerima sinyal dari thread untuk memperbarui UI (progress bar, tabel data).

3. **Background Process (utils.worker_thread):**
   - Menjalankan proses scraping di background agar UI aplikasi tidak freeze/not responding.
   - Memanggil fungsi-fungsi utama di selenium_scraper untuk memulai ekstraksi.
   - Mengambil hasil satuan artikel dari scraper dan memancarkannya kembali ke GUI secara real-time.

4. **Scraping Engine (scraper.selenium_scraper & scraper.article_extractor):**
   - selenium_scraper: Mengelola WebDriver, melakukan navigasi halaman, mengumpulkan link artikel, dan membuka setiap halaman artikel.
   - article_extractor: Menerima Web Element dari selenium_scraper dan mengekstrak komponen utama artikel seperti judul, tanggal, dan isi berita.

5. **Data Processing & Utilities (utils):**
   - date_filter: Menyaring artikel berdasarkan rentang tanggal yang dipilih pengguna.

- exporter: Menyimpan hasil scraping ke penyimpanan lokal dalam format CSV atau Excel.
- logger: Mencatat aktivitas program dan error ke konsol serta file log (app.log).

Secara keseluruhan, arsitektur ini memisahkan antarmuka pengguna dari proses scraping, serta memisahkan modul ekstraksi dan ekspor data sehingga mengikuti prinsip Single Responsibility.

Flowchart Alur Web Scraping

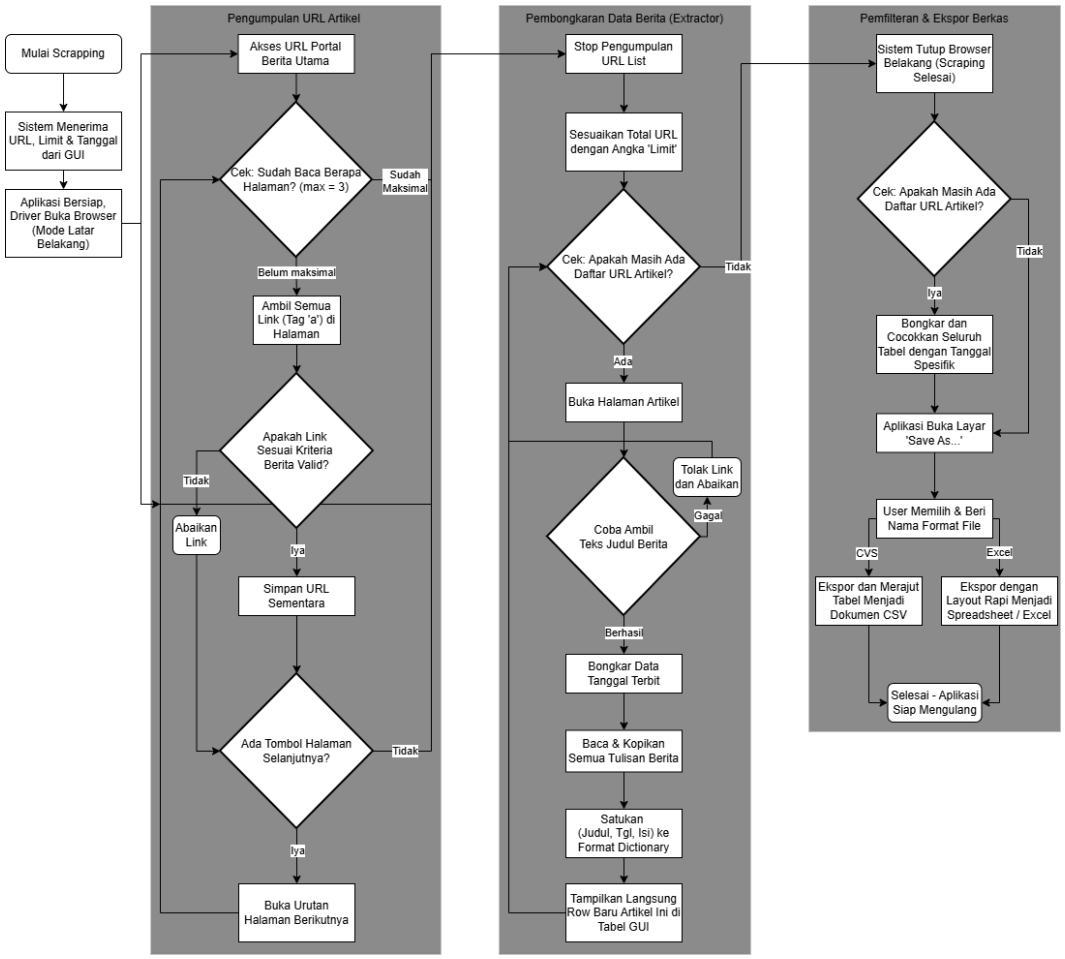

Proses dimulai ketika pengguna memasukkan URL berita dan menekan tombol Start. Sistem kemudian menyiapkan WebDriver dan mengakses halaman website untuk mengumpulkan seluruh link artikel berita yang valid, termasuk dari beberapa halaman jika tersedia. Setelah daftar link terkumpul, modul extractor membuka setiap artikel untuk mengambil judul, tanggal publikasi, dan isi berita, kemudian menampilkannya secara langsung pada tabel aplikasi. Jika terdapat halaman yang tidak valid, sistem akan melewatinya dan melanjutkan ke artikel berikutnya. Setelah seluruh proses selesai, pengguna dapat menerapkan filter tanggal jika diperlukan dan menyimpan hasil scraping ke dalam format CSV atau Excel melalui fitur export.